

从六篇 MVML 论文的目标函数读懂方法与创新

1. 共性背景：这六篇究竟在做什么

词	一句话	典型例子
多标签 (multi-label)	一个样本同时属于多个类，输出是一个 0/1 向量而不是一个类别号	一张图同时有"沙滩/天空/人"；一篇论文同时属于"机器学习/图论"
多视图 (multi-view)	同一个样本有多组特征，每组从不同角度描述它	一张图有 RGB 直方图 / GIST / 词袋；一篇文章有标题词袋 / 正文 TF-IDF / 引用网络
特征选择 (feature selection)	从 d 维里挑出 k 维 ($k \ll d$)，只输出排序，不输出分类器	从 1312 维里挑 20% = 262 维，再交给下游分类器

叠起来就是本文档的主角：**MVML-FS = 在多视图多标签数据上给特征排序。**

1.1 三个共同矛盾

- 共性与特性：**多个视图描述同一批样本，应当共享信息；但颜色特征能提供的线索，文本特征未必也有。强迫所有视图完全一致会丢掉互补信息。
- 标签有用，也可能有错：** Y 是监督信号，但实际标注可能包含误标和漏标。若完全相信 Y ，错误会传给特征权重；若过度去噪，又可能删掉真的标签。
- 选特征是离散决策，优化通常是连续的：**直接搜索全部特征子集代价太高，于是模型先学连续权重，用 $\ell_{2,1}$ 促使某些整行接近零，再取前 k 个特征。

1.2 六篇方法的共同框架

六篇论文都要学出特征权重，但**目标函数不是同一个式子换参数**。下面只是一个读各篇论文公式的框架：

$$\min_{\theta} \underbrace{\mathcal{L}_{\text{fit}}(\theta)}_{\text{特征拟合标签或潜表示}} + \sum_{k=1}^K \lambda_k \underbrace{\mathcal{R}_k(\theta)}_{\text{视图、标签等结构约束}} + \lambda_{\text{fs}} \underbrace{\Omega_{\text{fs}}(\theta)}_{\text{促进特征选择}}.$$

θ 代表该篇论文真正要学的变量；拟合部分可以不止一项。结构项的数量 K 也不固定：图平滑、视图重构、标签分解和张量约束只是不同论文的选择。最后一项常含 $\ell_{2,1}$ 行稀疏，但 EF²FS 作用于 A ，DHLI 同时作用于 W 和 U ，不能统一写成 $\delta \|W\|_{2,1}$ 。主拟合项前写系数 1 是常见的尺度约定，**不意味着六篇必须有相同数量或含义的平衡参数。**

谁在拟合谁？新学了什么变量？约束项希望它保留什么关系？最后用哪个矩阵给特征排序？这些问题都要到第二部分来讲解

1.3 经常出现的工具方法

(1) 平方误差：衡量两个矩阵有多接近

常见写法是 $\|A - B\|_F^2$ ，即把 A 和 B 对应位置的差逐一平方后相加。在这些论文里，它既可以要求“特征产生的预测接近标签”，也可以要求“某个视图能重构共享表示”。因此，看到这一项时先问：**谁在拟合谁？** 例如 ℓ^2 VSLC 的 $\|x^{(i)}w^{(i)} - y^{(i)}\|_F^2$ ，拟合的是第 i 个视图自己的潜标签，而不是直接拟合观测标签 Y 。

(2) 图平滑：让关系密切的样本保留相近的表示

用 S_{pq} 表示样本 p, q 的相似度， $L = D_S - S$ 表示图拉普拉斯矩阵。当 S 对称且非负时，对样本表示 F 有

$$\text{Tr}(F^\top L F) = \frac{1}{2} \sum_{p,q} S_{pq} \|F_{p,:} - F_{q,:}\|_2^2.$$

相似度越大，两个样本的表示差异受到的惩罚就越大。读图相关的式子，要分别看**图由什么信息建立**、**图约束哪个变量**： ℓ^2 VSLC 用视图特征建图，约束该视图的潜标签；UGRFS 用标签建图，约束全局表示。EF²FS 借助图平滑能量计算视图权重，但最终目标里没有再加入同形式的独立图惩罚项。

(3) $\ell_{2,1}$ 行稀疏：把特征权重变成排序依据

若权重矩阵 W 的第 j 行对应第 j 个特征，则

$$\|W\|_{2,1} = \sum_{j=1}^d \|W_{j,:}\|_2.$$

这一项倾向于把作用较小的特征对应的一整行压小。训练后再计算每行的范数，按大小选前 k 个特征。**但要核对被稀疏化和被排序的到底是哪个矩阵**：EF²FS 使用 A ，DHLI 学习公共与特有路权重后合并排序；加入 $\ell_{2,1}$ 也不保证结果恰好只有 k 行非零。

(4) 交替优化：一次先更新一组变量

这些方法往往同时学习特征权重、潜在表示和其他辅助变量，通常固定其余变量，轮流更新其中一组；部分论文还使用乘性更新。这是**求解目标函数的方法**，不是目标函数中新增的惩罚项。目标值随迭代下降可以说明求解过程的表现，不能单凭这条曲线断言找到全局最优解。

1.4 共用实验口径

论文通常以五折交叉验证、1%—20% 的特征预算和 AP、Coverage、Hamming Loss、Ranking Loss 四项指标评估。

七步实验流程


- 1.数据集准备（多样本多标签，视图已切好）
- 2.5 折交叉验证拆分（训练 / 测试）
- 3.在【训练集】上跑特征选择模型 → 学到特征权重 w → 全特征降序排序
- 4.取 top-k 个特征（k 扫描 1% ... 20% 的总特征数）
- 5.用这 k 个特征训练/预测多标签分类器
- 6.算 AP / Coverage / HL / RL 四项指标
- 7.对 20 个百分比点取均值，跨 5 折报 $\text{mean} \pm \text{std}$

补充分析（各篇按需做，不属于主流程）：参数敏感性分析、消融实验、收敛性分析、Friedman 检验、复杂度分析

关于四项指标的方向一般为 **AP 越高越好，其余三项越低越好**：AP 看相关标签能否排在前面，Coverage 看要走到排序多深才能覆盖样本的相关标签，Hamming Loss 看逐标签判错比例，Ranking Loss 看相关标签与不相关标签的相对顺序错了多少。

2. 六篇论文：逐项读目标函数

2.1 I²VSLC (Information Sciences 2024)：标签空间也会"不一致"



图：I²VSLC 的四个模块 —— (a) 特征权重获取、(b) 视图特有标签的自刻画、(c) 标签信息（相关矩阵→增强标签）、
(d) 层级特征选择。

问题动机：同一批样本的不同视图，不一定都能解释同一组标签。I²VSLC 因而给每个视图一份可学习的标签矩阵，再约束它们既保留自身信息、又不完全分裂。

目标函数

$$F_{I^2VSLC} = \underbrace{\sum_i \|x^{(i)} w^{(i)} - y^{(i)}\|_F^2}_{\text{① 视图} \rightarrow \text{自己的标签}} + \underbrace{\alpha \left(\sum_i \text{Tr}(y^{(i)\top} L^{(i)} y^{(i)}) + \sum_i \sum_{j \neq i} \|y^{(i)} - y^{(j)}\|_F^2 \right)}_{\text{② 自刻画函数 } \Phi(\cdot)} + \underbrace{\beta (\|YC - Y_{vs}\|_F^2 + \|Y - YC\|_F^2)}_{\text{③ 增强标签去噪}} + \underbrace{\gamma \sum_i \|w^{(i)}\|_F}_{\text{④ 视图级收缩}} + \underbrace{\delta \|W\|_{2,1}}_{\text{⑤ 特征级行稀疏}}$$

其中 $Y_{vs} = \mathbf{1}[\sum_i y^{(i)} \geq 1]$ 是各视图标签的 OR 聚合（注意论文显式定义 $\otimes$ 为 **OR** 而非 Kronecker 积）。

自刻画函数 $\Phi(\cdot)$ 的两项各有讲究：

$$\Phi(\cdot) = \underbrace{\sum_{i=1}^V \text{Tr}(y^{(i)\top} L^{(i)} y^{(i)})}_{\text{intra-view: 视图内流形平滑}} + \underbrace{\sum_{i=1}^V \sum_{j \neq i} \|y^{(i)} - y^{(j)}\|_F^2}_{\text{inter-view: 视图间共识}}$$

变量清单

符号	维度	角色
$y^{(i)}$	$n \times l$	学习参数： 第 i 个视图特有的标签
$w^{(i)}$	$d^{(i)} \times l$	学习参数： 视图自己的特征权重
$W = \bigoplus_i w^{(i)}$	$d \times l$	排序依据（纵向拼接）
C	$l \times l$	学习参数： 标签相关矩阵（ 全局共享 ）
Y_{vs}	$n \times l$	计算： 各视图标签的 OR
$L^{(i)}$	$n \times n$	已知：视图 i 的 特征 knn 图拉普拉斯

我的理解：目标函数如何串起整个方法

整体链路：每个视图先学习自己能够解释的潜标签，再把这些标签汇总，与观测标签建立联系，最后从视图权重中选特征。这里的箭头表示信息关系，所有变量仍在同一目标中联合学习。

$$X^{(i)} \xrightarrow{w^{(i)}} y^{(i)}, \quad Y_{vs} = \bigvee_i y^{(i)} \longleftrightarrow YC \longleftrightarrow Y.$$


- 先允许各视图说出不同的标签。** $\|x^{(i)} w^{(i)} - y^{(i)}\|_F^2$ 让视图 i 的特征预测自己的 $y^{(i)}$ ，而非要求所有视图直接预测同一个 Y 。这使“某个标签主要由少数视图提供证据”可以被模型表达。为防止 $y^{(i)}$ 任意变化，图项 $\text{Tr}(y^{(i)\top} L^{(i)} y^{(i)})$ 要求**该视图中特征相近的样本，潜标签也相近**；视图间的 $\|y^{(i)} - y^{(j)}\|_F^2$ 则防止各视图完全分裂。
- 再把各视图接回观测监督。** Y_{vs} 是视图潜标签的并集， YC 是通过全局共享的标签相关矩阵 C 得到的增强标签。 $\|YC - Y_{vs}\|_F^2 + \|Y - YC\|_F^2$ 同时连接“各视图推断”和“原始标注”，但没有强制 $Y_{vs} = Y$ 。因此，这里学的是受观测标签约束的潜标签，而不是给每个视图任意造一套标签。

3. **最后在两个粒度上压缩权重。** $\sum_i \|w^{(i)}\|_F$ 以整个视图为单位抑制弱视图， $\|W\|_{2,1}$ 以特征行为单位抑制弱特征，再用 W 的行范数排序。我的理解是：模型同时判断“哪些视图值得信”和“这些视图中的哪些特征值得留”；它并非先选视图、再选特征的两阶段流程。

####

创新点：视图特有标签 $y^{(i)}$ 是待学变量；视图内图平滑与视图间一致性共同约束它；视图级与特征级两种稀疏粒度共同影响选择。

2.2 GRAFS (Information Sciences 2024)：全局视图是"学"出来的



图：GRAFS 的整体流程——各视图特征相关性→候选视图（锚点表达）→重构视图→标签映射得到特征权重。

问题动机：把多视图特征直接拼接，并不等于理解了视图间关系。GRAFS 让全局视图成为待学习变量，并用锚点表示连接各视图。

目标函数

论文总目标（原文式 14；这里将五类项标为 a—e，锚点重构项只计一次）：

$$\begin{aligned}
 L_{\text{GRAFS}} = & \underbrace{\|X^f W - Y\|_F^2}_{(a) \text{ 全局视图预测标签}} + \underbrace{\alpha \sum_i v_i \|X^{(i)} - B P^{(i)}\|_F^2}_{(b) \text{ 锚点重构各视图}} \\
 & + \underbrace{\beta (\|B - W^c A^c R^c\|_F^2 + \|X^f - W^c A^f R^f\|_F^2 + \|A^c - A^f\|_F^2)}_{(c) \text{ 双路径与软一致性}} \\
 & + \underbrace{\gamma \sum_i v_i \|X^f D^{(i)} - X^{(i)} C^{(i)}\|_F^2}_{(d) \text{ 逐视图补充}} + \underbrace{\delta \|W\|_{2,1}}_{(e) \text{ 特征稀疏}}.
 \end{aligned}$$

变量清单 (k = 锚点数, k_1 = 潜锚点维数, d = 总特征数)

符号	维度	角色
B	$n \times k$	要学： 候选视图（锚点表达）
X^f	$n \times d$	要学： 全局视图（潜变量）
W	$d \times l$	要学： 全局视图上的特征权重 = 排序依据
W^c	$n \times k_1$	要学： 两条路径 共享 的簇成员矩阵
A^c, A^f	$k_1 \times k_1$	要学： 两条路径各自的潜锚点

符号	维度	角色
R^c / R^f	$k_1 \times k / k_1 \times d$	要学 : 锚点→候选视图 / 锚点→全局视图
$P^{(i)}$	$k \times d^{(i)}$	要学 : 用锚点重构第 i 个视图
$C^{(i)}$	$d^{(i)} \times d^{(i)}$	要学 : 视图内特征变换
$D^{(i)}$	$d \times d^{(i)}$	不更新 : 把 X^f 的列块切出来的选择矩阵
v_i	标量	算出来 : 视图权重

⚠️ **一处最容易搞错的维度**: 全局视图 X^f 是 $n \times d$ (与拼接后的特征同维), 不是 $n \times k$ 。因为最终排序矩阵 W 必须是 $d \times l$ (d 行才能给 d 个特征排序), 而 $X^f W$ 要等于 $n \times l$ 的 Y 。只有 B (候选视图) 是 $n \times k$, k 是锚点数。

我的理解：目标函数如何串起整个方法


整体架构可以看成两份相互牵制的潜表示：锚点表达 B 负责汇集各视图的结构，全局视图 X^f 负责把汇集后的信息用于标签预测和特征选择。两者都由数据约束，且在一个目标中一起更新； X^f 不是预先拼好的输入。

$$B \approx W^c A^c R^c, \quad X^f \approx W^c A^f R^f, \quad A^c \approx A^f.$$

- 从各视图形成锚点表达**。 $\sum_i v_i \|X^{(i)} - B P^{(i)}\|_F^2$ 要求同一份 B 经不同的 $P^{(i)}$ 能重构各视图。这促使 B 保留多个视图的信息； v_i 决定各视图在重构中的影响。
- 用双路径把 B 与 X^f 联系起来**。两条分解路径共享样本侧的 W^c ，但分别拥有 A^c, A^f ； $\|A^c - A^f\|_F^2$ 只鼓励二者接近。我的理解是：**共享坐标**提供跨视图的共性，**软对齐**给候选视图与全局视图各自留出调整空间。这里没有强制两个表示完全相同。
- 让全局视图既有监督意义，也保留原视图信息**。 $\|X^f W - Y\|_F^2$ 把 X^f 接到标签； $\|X^f D^{(i)} - X^{(i)} C^{(i)}\|_F^2$ 又要求它的第 i 个特征块与该视图对应。 $D^{(i)}$ 只是固定的取列矩阵。两端共同约束 X^f 后， $\|W\|_{2,1}$ 才能把 W 的行范数变成原始特征的排序。

串起来看：锚点重构负责“信息从哪里来”，双路径负责“不同表示怎样共享结构”，标签预测与逐视图对应负责“全局表示是否有用”。压缩可能有助于降噪，但不能仅凭这套结构断言噪声一定被去除。

创新点：全局视图 X^f 由标签预测、锚点路径和逐视图还原三方共同决定； W^c 共享而 A^c, A^f 只作软对齐，给特有信息留了空间。



Labels: Rain, Relaxing, Coffee shop

图：论文的动机例子（论文 Fig.1 上半部分）—— 一个视频的多个视图（画面 / 标题 / 简介）给出 "Rain, Relaxing, Coffee shop" 这组标签。EF²FS 关心的是：这些视图该怎么融合，融合与选择能不能一起做。

问题动机：先融合、后选特征的两步流程中，融合阶段不知道下游到底要哪些特征。EF²FS 把融合、公共表示和特征权重放进同一个目标函数。

目标函数

$$\min_{A,G,B,w^{(i)}} \underbrace{\|X^f A - G\|_F^2}_{\text{① 融合} \rightarrow \text{嵌入}} + \underbrace{\alpha \|Y - GB^T\|_F^2}_{\text{② 嵌入} \rightarrow \text{标签}} + \underbrace{\beta \sum_i \|x^{(i)} w^{(i)} - G\|_F^2}_{\text{③ 各视图} \rightarrow \text{嵌入}} + \underbrace{\gamma \sum_i \|a^{(i)} - w^{(i)}\|_F^2}_{\text{④ 全局块} \leftrightarrow \text{局部}} + \underbrace{\delta \|A\|_{2,1}}_{\text{⑤ 行稀疏} \rightarrow \text{排序}}$$

s.t. $G \geq 0, B \geq 0$

视图权重与融合矩阵（论文式(12)(9)，注意论文先给 y 版（式(8)）再改成 G 版）：

$$c_i = \frac{1/\text{Tr}(G^T L^{(i)} G)}{\sum_{j=1}^V 1/\text{Tr}(G^T L^{(j)} G)}, \quad X^f = [c_1 x^{(1)}, c_2 x^{(2)}, \dots, c_V x^{(V)}]$$

变量清单

符号	维度	角色
$x^{(i)}$	$n \times d^{(i)}$	已知特征块
X^f	$n \times d$	算出来：视图加权拼接
A	$d \times k$	要学：融合后的特征权重 = 最终排序依据
G	$n \times k$	要学：隐标签 / 公共嵌入 (k = 隐空间维数)
B	$l \times k$	要学：从嵌入 G 回到标签的映射
$w^{(i)}$	$d^{(i)} \times k$	要学：每个视图各自的局部投影
c_i	标量	算出来：视图权重

我的理解：目标函数如何串起整个方法

整体架构围绕一个公共嵌入 G 展开：加权融合后的特征和每个原始视图都要能生成 G ，而 G 又必须能解释观测标签。这样，融合、标签信息与特征权重在训练时会互相影响。

$$X^f = [c_1 x^{(1)}, \dots, c_V x^{(V)}], \quad X^f A \approx G, \quad x^{(i)} w^{(i)} \approx G, \quad G B^\top \approx Y.$$

1. **用 G 汇合三种信息。** $\|X^f A - G\|_F^2$ 让融合特征产生公共嵌入； $\sum_i \|x^{(i)} w^{(i)} - G\|_F^2$ 让每个视图各自也能产生它； $\|Y - G B^\top\|_F^2$ 再保证 G 与标签任务有关。 G 因而是连接各视图与监督信号的中间表示，不能仅因它维度较低就断言已经去噪。
2. **让融合权重受到当前表示的反馈。** 令 $E_i = \text{Tr}(G^\top L^{(i)} G)$ ，论文按 $c_i \propto 1/E_i$ 给视图加权：若 G 在视图 i 的图上更平滑，该视图的权重就更大。随后 c_i 改变 X^f ， X^f 又影响 A 和 G 的更新，形成“表示 $\rightarrow$ 视图权重 $\rightarrow$ 融合 $\rightarrow$ 表示”的循环。 E_i 接近零时，实际计算还需要数值保护。
3. **把全局选择与局部选择对齐。** A 的第 i 个行块 $a^{(i)}$ 与局部投影 $w^{(i)}$ 通过 $\|a^{(i)} - w^{(i)}\|_F^2$ 相互约束，避免两套权重各说各话。最终 $\|A\|_{2,1}$ 压低弱特征的整行，并按 A 的行范数排序；这里的输出是 A ，不是各个 $w^{(i)}$ 的简单拼接。

我的理解：这篇的“嵌入式”体现在选特征的 A 直接参与公共嵌入的学习，视图权重也随 G 改变。要证明这种联合学习比固定融合后再选特征更好，还应做相同融合规则下的两阶段对照。

创新点：融合特征 X^f 、公共嵌入 G 和各视图投影在一个目标中相互影响；全局权重块 $a^{(i)}$ 与局部权重 $w^{(i)}$ 之间有显式一致性项。

2.4 DHLI (AAAI 2024)：把“噪声”变成一等变量



Labels
(noisy ones in red,
common ones in green)

Pop

JAZZ

coffee
shop

guitar

tranquility

图：论文的动机例子——一个视频的“标签”里，绿色是公共标签，红色是噪声标签。

DHLI 的主张是：噪声不该被“启发式滤掉”，而该被显式求解出来。

问题动机：观测标签可能混有公共信息、视图独有信息和错误标注。DHLI 把这三类标签显式分开，让去噪参与特征权重的学习。

目标函数

第一层（标签矩阵层），Def.1；第二层（视图层），Def.2：

$$Y = \underbrace{Y_c}_{\text{公共}} \otimes \underbrace{Y_s}_{\text{视图特有}} \otimes \underbrace{Y_n}_{\text{噪声}}$$

Y_s 是总体的视图特有标签矩阵，由各视图的 $y_s^{(i)}$ 通过并集一致项约束；它不是把 V 个矩阵简单横向拼接。

$$\bigcirc_i y_s^{(i)} = \prod_i y_s^{(i)} = 0 \text{ (AND, 必须为 0)}, \quad \bigotimes_i y_s^{(i)} = Y_{tem} \approx Y_s \text{ (OR, 须等于 } Y_s \text{)}$$

完整目标（论文式(12)）：

$$\begin{aligned} \min & \underbrace{\sum_{i=1}^V \|X^{(i)}W^{(i)} - Y_c\|_F^2}_{\text{各视图} \rightarrow \text{公共标签}} + \underbrace{\sum_{i=1}^V \|X^{(i)}U^{(i)} - y_s^{(i)}\|_F^2}_{\text{各视图} \rightarrow \text{自己特有标签}} \\ & + \alpha \underbrace{\|Y \ominus Y_c\|_F^2}_{\text{公共占多数}} + \beta \underbrace{\|Y_n\|_1}_{\text{噪声稀疏}} + \gamma (\|W\|_{2,1} + \|U\|_{2,1}) \\ & + \delta \left(\underbrace{\|\bigcirc_i y_s^{(i)}\|_F^2}_{\text{(f) 视图互斥}} + \underbrace{\|\bigotimes_i y_s^{(i)} \ominus Y_s\|_F^2}_{\text{(g) 并集一致}} \right) \end{aligned}$$

四个算子清单：

算子	名字	在 $\{0, 1\}$ 上的实际计算	语义
$\otimes$	OR / 并集	$\mathbf{1}[\sum_i (\cdot) \geq 1]$	"至少一个视图说它是"
$\circ, \oplus, \prod$	AND / 交集	$\prod_i (\cdot)$	"所有视图都说它是"（全票通过）
$\ominus$	XOR	$\mathbf{1}[a \neq b]$	"不一致"指示器 $\rightarrow$ 惩罚项
$\ \cdot\ _1$	ℓ_1	$\sum_{pq} (\cdot)_{pq} $	稀疏

我的理解：目标函数如何串起整个方法

整体架构是“先解释观测标签由哪些成分组成，再让特征分别预测这些成分”。 Y_c 表示跨视图公共部分， $y_s^{(i)}$ 表示视图 i 特有部分， Y_n 承担噪声；两套特征权重分别服务于公共和特有标签。

$$Y = Y_c \otimes Y_s \otimes Y_n, \quad X^{(i)}W^{(i)} \approx Y_c, \quad X^{(i)}U^{(i)} \approx y_s^{(i)}.$$

- 两路预测对应“共性”和“互补性”。** 所有视图通过 $W^{(i)}$ 拟合同一个 Y_c ，使公共标签有多视图证据；每个视图又通过 $U^{(i)}$ 拟合自己的 $y_s^{(i)}$ ，避免只学公共部分而忽略视图特长。这里不要求某个视图独自预测完整的观测标签 Y 。
- 标签分解需要约束，否则三类成分可以互相推卸。** $\|Y \ominus Y_c\|_F^2$ 倾向于让公共部分解释较多观测标签， $\|Y_n\|_1$ 倾向于让噪声只占少量位置；这两项体现的是建模先验。对特有部分， $\bigcirc_i y_s^{(i)} \approx 0$ 防止“所有视图都称它为特有”， $\bigotimes_i y_s^{(i)} \approx Y_s$ 要求总体特有标签由各视图认领。这样， Y_c, Y_s, Y_n 才各有角色。
- 两路权重共同决定特征排序。** $\|W\|_{2,1} + \|U\|_{2,1}$ 同时压缩公共路和特有路的无关特征；最终要结合两路权重，不能只看 W 。论文用组合后的行范数排序，仓库实现还分别归一化 W, U 后再合并，复现时应明确采用哪一种口径。

我的理解：DHLI 真正改变的是“标签目标”而不只是增加一项去噪正则。若数据中的公共标签并不占多数，或噪声是成片出现的，分解质量就需要额外检验。

创新点：把标签噪声从模糊的“要去掉的东西”变成显式 Y_n ；公共和特有标签分别由两套权重拟合；“全视图都特有”与“特有部分没人认领”由逻辑约束处理。

2.5 UGRFS (AAAI 2025)：同一视图里的样本也有质量差异




Figure 1: Four typical types for the relationship between features and labels in MVML, namely, a) common-based mapping including ① and ④, b) label consistency mapping including ②, c) view-specific mapping including ③, and d) concatenation view mapping including ④.

Nevertheless, the effective learning of weights for all features remains a challenging task due to the inherent many-to-one mapping relationship.

Moreover, it is worth considering the relaxation of the assumption that the reliability of each view, and even each sample, is uniformly equal to 1. In reality, the quality of histopathological images may vary across different patients (Yagi 2011), and tabular data may contain feature noise (Yelipe, Porika, and Golla 2018). As a result, there can be disparate confidence levels across samples. Therefore, the

sequently, extensive experiments are conducted on several multi-view multi-label datasets. The experimental results validate the superiority of UGRFS over state-of-the-art methods.

Related Work

Multi-Label Feature Selection

In the multi-label scenario, instances are associated with

图：论文归纳的 MVML 中特征-标签关系的四种典型范式（共识映射 / 标签一致映射 / 视图特有映射 / 拼接映射）——

UGRFS 的定位是“这四者之外”。

问题动机：即使在同一个视图里，不同样本也未必同样可靠。UGRFS 学习样本级置信系数，并让它与全局视图重构共同影响特征排序。

目标函数

$$\min_{W^{(i)}, C^{(i)}, W_y^{(i)}} \sum_{i=1}^V \left\| \text{diag}(C^{(i)}) X^{(i)} W^{(i)} - Y \right\|_F^2 + \alpha \text{Tr}(D^\top L_Y D) + \beta \sum_{i=1}^V \left\| D^{(i)} - \text{diag}(C^{(i)}) X^{(i)} \right\|_F^2 + \gamma \|D - X^f\|_F^2 + \delta \|W\|_{2,1}$$

其中 $D = Y_x W_y$ 是学出来的全局视图分布， $Y_x = [\rho(Y), J_1] \in \mathbb{R}^{n \times (n+1)}$ ， $X^f = [v_1 X^{(1)}, \dots, v_V X^{(V)}]$ 是传统的视图加权拼接。

变量清单

符号	维度	角色
$W^{(i)}$	$d^{(i)} \times l$	要学：每个视图自己的特征权重
$W = \bigoplus_i W^{(i)}$	$d \times l$	排序依据：纵向拼接后的整体权重
$C^{(i)}$	n (对角)	要学：样本级置信度
D (全局视图分布)	$n \times d$	要学：学出来的全局视图
$D^{(i)}$	$n \times d^{(i)}$	要学： D 在第 i 个视图上的分量

符号	维度	角色
$W_y^{(i)}$	$(n+1) \times d^{(i)}$	要学：从标签核空间回归出全局视图的系数
v_i	标量	算出来：视图权重

我的理解：目标函数如何串起整个方法

整体架构有两条相连的线：各视图用特征权重 $W^{(i)}$ 预测标签；模型另学一个全局表示 D ，使它既受标签关系引导，又能对应回各视图。每个视图中的每个样本还有自己的置信系数 $C^{(i)}$ ，它同时进入这两条线。


$$\text{diag}(C^{(i)})X^{(i)}W^{(i)} \approx Y, \text{quad} D^{(i)} \approx \text{diag}(C^{(i)})X^{(i)}, \quad D \approx X^f.$$

- 让样本可靠性参与标签预测。** 第 i 个视图的第 m 个样本先乘 $c_m^{(i)}$ ，再通过 $W^{(i)}$ 产生预测；因此同一视图的样本不必被同等对待。但这一项是 $\|\text{diag}(C^{(i)})X^{(i)}W^{(i)} - Y\|_F^2$ ，**缩放的是特征和预测，不是把整行残差乘上置信度。**所以“ $C^{(i)}$ 学到了可靠性”仍是需要实验检验的解释。
- 给全局表示两个参照。** $D = Y_x W_y$ 使 D 可以由标签核表示生成， $\text{Tr}(D^\top L_Y D)$ 进一步要求标签相近的样本在 D 中也相近；这里的图建在标签上。另一方面， $\|D - X^f\|_F^2$ 使 D 接近视图加权拼接的 X^f ， $\sum_i \|D^{(i)} - \text{diag}(C^{(i)})X^{(i)}\|_F^2$ 让它的各个视图分量对应置信度调整后的原始特征。这样 D 同时受标签结构和特征信息约束。
- 两条线通过 $C^{(i)}$ 相互影响。** 改变样本置信度，会同时改变该样本的标签预测及其对全局视图的对应关系；更新 D 和 $W^{(i)}$ 又会反过来改变适合的 $C^{(i)}$ 。最后把各 $W^{(i)}$ 纵向拼成 W ，用 $\|W\|_{2,1}$ 及其行范数完成特征排序。

我的理解：UGRFS 把“哪个视图重要”细化到“这个视图里的哪个样本可信”。但置信系数的数学作用是预测缩放，是否真能识别脏样本，应通过可控噪声实验验证。

创新点：把可靠性细化到每个视图的每个样本；置信系数同时进入预测与全局视图的视图分量重构，使可靠性和表示互相影响。

2.6 TOCL (ACM MM 2025)：把标签诱导的样本关系堆成张量



图：TOCL 的四个组件——I 局部线性映射、II 全局非线性映射、III 视图特有标签间的张量相关、IV 离散标签相关。

问题动机：两两标签一致性未必能表达多个视图同时存在的关系。TOCL 把各视图标签诱导的样本关系堆成张量，并并行使用线性和非线性映射。

目标函数

TOCL 把五个组件拼成一个目标（论文式(14)）：

$$\begin{aligned} \min_{y_t^{(i)}, P, W, U, V, Y_n, T} \quad & \underbrace{\sum_{i=1}^V \left\| P X^{(i)} A^{(i)} W - y_t^{(i)} \right\|_F^2 + \|Z - T\|_F^2 + \tau \|T\|_*}_{\text{实例级映射 + 张量约束}} \\ & + \underbrace{\alpha \left\| P X W - \frac{I}{I + e^{-XV}} U \right\|_F^2 + \|U\|_F^2 + \|V\|_F^2}_{\text{全局非线性映射}} \\ & + \underbrace{\beta \|P\|_F^2}_{\text{限制 } P} + \underbrace{\gamma (\|Y_{all} \otimes Y_n\|_F^2 + \|Y_n\|_F^2)}_{\text{离散标签相关 (IV)}} + \underbrace{\delta \|W\|_{2,1}}_{\text{行稀疏} \rightarrow \text{排序}} \end{aligned}$$

两个配套定义（Def.3 / Def.4，注意 TOCL 的 $\otimes$ 是**逐元素 OR**）：

$$Y = Y_{all} \otimes Y_n, \quad Y_{all} = y_t^{(1)} \otimes y_t^{(2)} \otimes \cdots \otimes y_t^{(V)}$$

张量怎么造：第 i 个视图的潜标签可形成一个 $n \times n$ 的**样本关系矩阵**，沿视图维堆叠后得到三阶张量：

$$T_{:,i,:} = y_t^{(i)} y_t^{(i)\top} \in \mathbb{R}^{n \times n} \implies T \in \mathbb{R}^{n \times V \times n}$$

变量清单

符号	维度	角色
W	$d \times l$	要学 ：全局特征权重 = 最终排序依据
$A^{(i)}$	$d^{(i)} \times d$	不更新 ：把 W 的对应行块"取出来"的 0/1 选择矩阵
P	$n \times n$	要学 ：两路映射的耦合器
$y_t^{(i)}$	$n \times l$	要学 ：第 i 个视图的视图特有标签
U	$k \times l, k = \lfloor 0.8l \rfloor$	要学 ：隐标签关联矩阵
V	$d \times k$	要学 ：非线性映射的投影系数
T / Z	$n \times V \times n$	T 由潜标签诱导并受核范数约束； Z 是与它匹配的辅助张量
Y_n	$n \times l$	要学 ：显式噪声标签

我的理解：目标函数如何串起整个方法

整体架构可以从“标签怎样约束特征权重”来读：观测标签 Y 约束各视图的潜标签 $y_t^{(i)}$ ；潜标签分别约束对应视图的线性预测，并共同生成一个跨视图关系张量；全局非线性分支再与线性分支保持一致。最终，所有视图共用的 W 给特征排序。

$$Y_{all} = \bigotimes_i y_t^{(i)}, \quad Y_{all} \otimes Y_n \approx Y, \quad P X^{(i)} A^{(i)} W \approx y_t^{(i)}.$$

1. **局部线性分支保留视图特有的预测目标。** 每个视图用自己的 $X^{(i)}$ 拟合自己的 $y_t^{(i)}$ ，但通过固定的取块矩阵 $A^{(i)}$ 共用一份全局 W 。因此“标签目标因视图而异”和“特征排序在全局统一”可以同时存在。 $P \in \mathbb{R}^{n \times n}$ 在样本方向做混合，并由 $\beta \|P\|_F^2$ 限制幅度；不能把它简单当作对角的逐样本权重。




图: $A^{(i)}$ 从全局 W 中取出视图 i 对应的行块。

2. **张量分支约束不同视图的样本关系。** 每个 $y_t^{(i)} y_t^{(i)\top}$ 表示由该视图潜标签诱导的样本间关系，沿视图维堆成 $T \in \mathbb{R}^{n \times V \times n}$ 。 $\|Z - T\|_F^2 + \tau \|T\|_*$ 让关系张量与辅助张量 Z 保持接近，并用张量核范数鼓励较简单的跨视图关系结构。这比逐视图单独约束关系多了一层跨视图联系，但收益与计算代价仍要通过实验比较。
3. **全局非线性分支提供另一种映射形式。** $\|PXW - \sigma(XV)U\|_F^2$ 让线性预测与 sigmoid 分支的输出接近， $\|U\|_F^2 + \|V\|_F^2$ 控制其参数规模。 U, V 没有直接拟合 Y ，主要通过与线性分支一致来接受监督；所以“非线性带来了独立信息”仍需消融实验支持。
4. **标签约束把以上分支接回真实标注。** Y_{all} 是各视图潜标签的 OR 聚合， $\|(Y_{all} \otimes Y_n) \ominus Y\|_F^2$ 要求它与噪声变量共同解释 Y ； $\|Y_n\|_F^2$ 控制噪声变量大小，并非 ℓ_1 稀疏。最后 $\|W\|_{2,1}$ 压低无关特征的权重行，按 $\|W_{j,:}\|_2$ 排序。

我的理解： TOCL 的各模块最终都围绕 $y_t^{(i)}$ 与共享 W 相互作用；张量约束负责跨视图关系，双映射负责表达形式，离散标签项负责把潜标签拉回观测监督。

创新点： 局部线性映射与全局非线性映射互相约束；各视图标签诱导的样本关系被堆为张量，再用低秩约束捕捉跨视图结构；最终仍用共享的 W 排序。

3. 跨篇比较：各自放松了什么假设

方法	重点改动	最终排序依据
I ² VSLC	每视图标签 $Y^{(i)}$	拼接后的 W 行范数
GRAFS	锚点引导的全局视图 X^f	全局 W 行范数
EF ² FS	融合与特征选择联合优化	A 行范数
DHLI	公共、特有、噪声标签分解	公共与特有二路权重
UGRFS	样本级置信度与全局视图	拼接后的 W 行范数

方法	重点改动	最终排序依据
TOCL	标签诱导样本关系张量、线性与非线性双路	全局 W 行范数

4. 梳理六篇算法后的启发

4.1 我学到的读论文方法

先找假设，再看它怎样进入式子。 例如 l^2 VSLC 放松“每个视图的标签一样”，对应新变量 $y^{(i)}$ ；GRAFS 放松“全局视图只能拼接”，对应待学的 X^f ；UGRFS 放松“同一视图中每个样本一样可靠”，对应 $C^{(i)}$ 。变量出现以后，还必须约束让它不任意漂移： l^2 VSLC 用共识和观测标签，GRAFS 用原视图重构和标签预测，UGRFS 用全局视图的一致性。这样读，比背四个超参数叫什么更可靠。

每一个新增变量都对应一个新的验证责任。 若声称学到“视图特有标签”，应展示它与公共标签有什么不同；若声称学到“样本置信度”，应展示低质量样本确实得到低置信；若声称张量捕捉高阶关系，应比较简单低秩替代项。只报告最终 AP 上升，很难知道是哪一项起作用。

论文中的优化式、代码中的更新和最终指标是三层证据。 目标函数说明作者希望模型做什么；更新式决定代码实际上在做什么；下游指标只说明某套实验流程的结果。三层若不一致，不能拿最末端的分数替前两层作证明。例如本仓库的若干复现实现与论文在图或变量参数化上有差别，应当以原文解释论文、以运行记录说明代码。

4.2 从六篇中浮现的三个研究问题

问题 A：统一的视图权重是否过粗？ GRAFS、EF²FS 等方法都在某种程度上给一个视图整体分配权重，但一个视图对标签“天空”有用，并不意味着它对标签“奔跑”也有用。我的想法是把视图权重从 v_i 扩为标签条件权重 $r_{i,q}$ ：第 i 个视图对第 q 个标签有多可靠。这不是简单多加一张矩阵；若没有归一化、稀疏或可辨识约束，它可能只会过拟合。因此第一步应先做可控数据检验，而不是直接堆复杂模型。

问题 B：图权重对数据尺度是否稳定？ 多篇工作依赖图能量 $\text{Tr}(G^\top L^{(i)} G)$ 。图的构造、特征缩放和热核带宽都可能改变该量。这里不能只根据一个代数式就宣称“所有视图权重会塌缩”；尤其对所有视图共享的 G 同乘一个常数时，归一化后的 $1/E_i$ 权重并不会因此改变。真正要检验的是**各视图特征尺度、图构造参数和数值精度**改变后的稳定性。这个问题适合设计小规模、可重复的实验。

问题 C：复杂结构带来的收益是否抵得上代价？ GRAFS 要学多组锚点与分解矩阵，TOCL 要做张量运算。复杂结构可能带来表达能力，但也增加超参数、内存和运行时间。比较时应在相同划分和特征预算下，同时报告指标、方差、耗时和解释性；否则“模型更复杂”容易被误读为“模型更好”。